

PROPOSTA DO PROJETO FINAL

Background do domínio

O câncer de pele é um grande problema de saúde pública, com mais de 5 milhões de casos recém diagnosticados nos Estados Unidos a cada ano. O melanoma é a forma mais letal de câncer de pele, responsável por mais de 9.000 mortes a cada ano.

Dermatoscopia

Como lesões pigmentadas que ocorrem na superfície da pele, o melanoma é passível de detecção precoce por inspeção visual especializada. Também é passível de detecção automatizada com análise de imagem. Dada a ampla disponibilidade de câmeras de alta resolução, os algoritmos que podem melhorar nossa capacidade de rastrear e detectar lesões problemáticas podem ser de grande valor. Como resultado, muitos centros iniciaram seus próprios esforços de pesquisa em análises automatizadas. No entanto, um esforço centralizado, coordenado e comparativo entre as instituições ainda precisa ser implementado.

Dermatoscopia é uma técnica de imagem que elimina o reflexo da superfície da pele. Ao remover a reflexão da superfície, a visualização de níveis mais profundos da pele é aprimorada. Pesquisas anteriores mostraram que, quando usada por especialistas em dermatologia, a dermatoscopia oferece maior precisão diagnóstica, em comparação com a fotografia padrão. À medida que os acessórios de dermatoscópio baratos para smartphones estão começando a chegar ao mercado, aumenta a oportunidade de algoritmos automatizados de avaliação dermatoscópica influenciarem positivamente o atendimento ao paciente.

Com base nessas informações, me senti motivado a desenvolver como projeto final de conclusão de curso, um algoritmo de machine learning para detectar o câncer de pele.

Artigos de referências:

<https://arxiv.org/ftp/arxiv/papers/1703/1703.03108.pdf>

<https://arxiv.org/pdf/1703.01976.pdf>

<https://arxiv.org/abs/1703.04819>

<https://arxiv.org/pdf/1710.05006.pdf>

A enunciação do problema

O câncer de pele é a forma mais comum da doença, nos EUA 5,4 milhões de novos casos são diagnosticados por ano, podem ser carcinomas ou melanomas, que é a forma mais mortal, estima-se que 20% dos americanos vão ter câncer de pele, felizmente na maioria dos casos é benigno, o pré-câncer afeta 58 milhões de americanos e muitas pessoas no mundo, nos EUA são registrados 76 mil casos de melanoma por ano, e aproximadamente 10 mil mortes, os EUA gastam em torno de US\$ 8,1 bilhões por ano com tratamento e diagnóstico, a taxa de sobrevivência em 5 anos para o melanoma de estágio 4 é de aproximadamente 15-20%, enquanto que no estágio 0 é de 99-100%, portanto detectar a doença nos estágios iniciais é primordial.

Conjunto de dados e inputs

Os dados e objetivos foram obtidos do 2017 ISIC Challenge on Skin Lesion Analysis Towards Melanoma Detection.

O International Skin Imaging Collaboration (ISIC) é um esforço internacional para melhorar o diagnóstico do melanoma, patrocinado pela Sociedade Internacional de Imagem Digital da Pele (ISDIS). O Arquivo ISIC contém a maior coleção publicamente disponível de imagens dermatoscópicas controladas de qualidade de lesões de pele.

Os inputs são imagens de lesões: melanoma, nevos e queratose sebórréica obtidas do ISIC Archive contém mais de 13.000 imagens dermatoscópicas, que foram coletadas dos principais centros clínicos internacionalmente e adquiridas a partir de uma variedade de dispositivos dentro de cada centro. A participação ampla e internacional na contribuição da imagem é projetada para garantir uma amostra representativa clinicamente relevante. Os conjuntos de dados iniciais derivam principalmente dos Estados Unidos, e o ISIC tem compromissos e contribuições contínuos de conjuntos de dados adicionais de colaboradores internacionais.

Todas as imagens recebidas no ISIC Archive são rastreadas para garantia de privacidade e qualidade. A maioria das imagens tem metadados clínicos associados, que foram avaliados por especialistas reconhecidos em melanoma. Um subconjunto das imagens foi submetido a anotações e marcações por especialistas reconhecidos em câncer de pele. Essas marcações incluem características dermatoscópicas (isto é, elementos morfológicos globais e focais na imagem conhecidos por discriminar entre os tipos de lesões da pele).

esses dados são ideais para treinar a rede, pois contém imagens suficientes com todas as características para que ela possa reconhecer os 3 tipos de doenças.

Link do dataset:

<https://challenge.kitware.com/#challenge/583f126bcad3a51cc66c8d9a>"<https://challenge.kitware.com/#challenge/583f126bcad3a51cc66c8d9a>

Explicação da solução

O Objetivo do projeto é criar um algoritmo usando uma rede neural convolucional (CNN) para detectar o câncer de pele, especificamente a rede consegue distinguir entre a forma mais mortal de câncer o melanoma, e outras duas lesões de pele benignas: nevos e queratose sebórréica.

CNNs são ideais para resolver o problema em questão porque conseguem processar e detectar padrões em milhares de imagens, redes neurais convolucionais funcionam baseando-se em uma operação matemática conhecida como convolução, no qual um filtro percorre cada canal da imagem em busca de padrões.

Os modelos de benchmark

A equipe de Sebastian Thrun publicou um trabalho na Nature, no qual treinam uma CNN para diagnosticar câncer de pele, usando a base de dados DSA internacional, e surpreendentemente obteve uma precisão de 71%, um resultado muito melhor que os melhores médicos dermatologistas humanos, de acordo com o artigo abaixo:

https://www.nature.com/articles/nature21056.epdf?author_access_token=8oxlcYWf5UNrNpHsUHd2StRgN0jAjWel9jnR3ZoTv0NXpMHRAJy8Qn10ys2O4tuPakXos4UhQAFZ750CsBNMMsISFHIKinKDMKjShCpHIIYPYUHHNzkn6pSnOct0Ftf6

Métricas de avaliação

Inspirado pelo desafio ISIC, seu algoritmo será classificado segundo três categorias separadas.

Categoria 1: ROC AUC para Classificação de Melanoma

Na primeira categoria, avaliaremos a habilidade da sua CNN distinguir entre melanoma maligno e lesões de pele benignas (nevus, queratose seborréica) calculando a área sob a curva característica de operação do receptor (ROC AUC) correspondente a esta tarefa de classificação binária.

Categoria 2: ROC AUC para Classificação Melanocítica

Todas as lesões de pele que examinaremos são causadas pelo crescimento anormal de [melanócitos] ou [queratinócitos], que são dois tipos diferentes de células epidérmicas da pele. Melanomas e nevus são derivados de melanócitos, enquanto queratoses seborréicas são derivadas de queratinócitos.

Na segunda categoria, avaliaremos a habilidade da sua CNN distinguir entre lesões de pele melanocíticas e queratinocíticas, calculando a área sob a curva característica de operação do receptor (ROC AUC) correspondente a esta tarefa de classificação binária.

Categoria 3: ROC AUC média

Na terceira categoria, tiraremos a média dos valores ROC AUC das duas primeiras categorias.

Esboço do Design do Projeto

Esse documento é apenas uma proposta de projeto, durante a etapa de desenvolvimento é que vou fazer os testes e verificar o que funciona e o que não funciona, mas por enquanto pretendo desenvolver o projeto me baseando nos artigos de referência citados anteriormente, mas a princípio, pretendo criar uma CNN usando Keras, e seguir a seguinte metodologia:

Pré-processamento dos dados:

Cada pixel da imagem pode ter qualquer valor entre 0 e 255, portanto todos os pixels devem ser divididos por 255 para que cada um deles seja um número entre 0 e 1, para que sejam normalizados.

Divisão dos dados:

Os dados são divididos em conjuntos de treinamento, validação e teste, usando transferência de aprendizado, usando os recursos de gargalo fornecidos por uma rede DenseNet169.

Arquitetura temporária da rede:

DN169_top = Sequential()

```
DN169_top.add(GlobalAveragePooling2D(input_shape=train_DN169.shape[1:]))
```

```
DN169_top.add(Activation('elu'))
```

```
DN169_top.add(Dropout(0.2))
```

```
DN169_top.add(Dense(512, activation='elu'))
```

```
DN169_top.add(Dropout(0.4))
```

```
DN169_top.add(Dense(len(disease_names), activation='softmax'))
```

Configurando os Hiper-parâmetros:

Antes de treinar o modelo é necessário configurar os melhores Hiper-parâmetros, o número de épocas, taxa de aprendizado, tamanho do lote, etc...

Eu costumava fazer isso através de tentativa e erro, mas existem formais mais eficientes de fazer isso, automatizando todo o processo, como por exemplo, usando o serviço Azure Machine Learning, que testa várias combinações de hiper-parâmetros e retorna aquela que obteve a melhor precisão no conjunto de validação.

Treinamento e Testes:

Durante a fase de treinamento pretendo estender o conjunto de dados usando a classe ImageDataGenerator, e testa-las de acordo com as métricas de avaliação definidas acima.